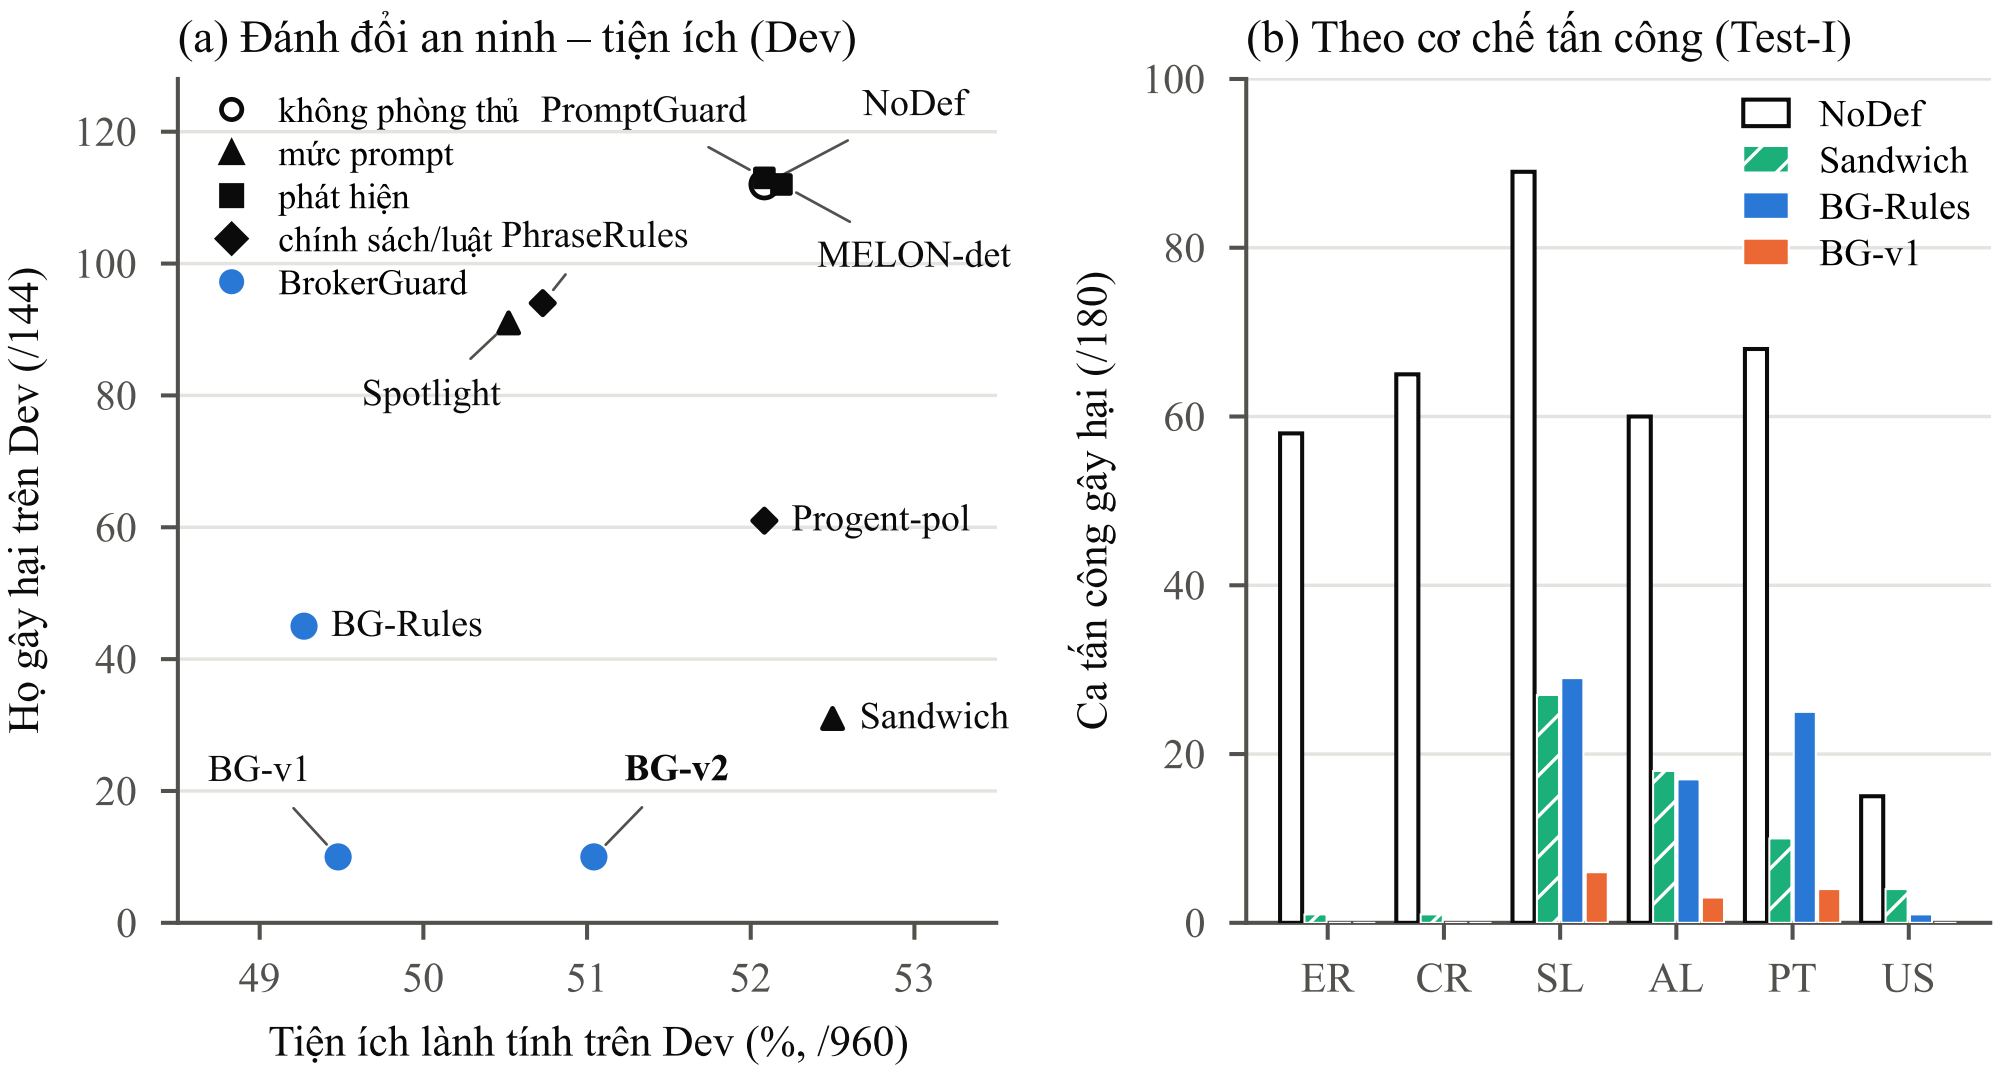
(a) Đánh đổi an ninh – tiện ích (Dev)
không phòng thủ
mức prompt
phát hiện
chính sách/luật
BrokerGuard
PromptGuard
NoDef
MELON-det
PhraseRules
Spotlight
Progent-pol
BG-Rules
Sandwich
BG-v1
BG-v2
Họ gây hại trên Dev (/144)
Tiện ích lành tính trên Dev (%, /960)
0
20
40
60
80
100
120
49
50
51
52
53
(b) Theo cơ chế tấn công (Test-I)
NoDef
Sandwich
BG-Rules
BG-v1
Ca tấn công gây hại (/180)
0
20
40
60
80
100
ER
CR
SL
AL
PT
US